

计算智能讲义——MaxSAT 问题

计算机科学与技术学院 M201973122 李研

1 Definition

首先给出以下符号定义：

Symbol	Definition	Description
x_i	<i>Variable</i>	变元, $x_i + \bar{x}_i = 1, i = 1, 2, \dots, n$
C_i	<i>Clause</i>	子句, $C_i = \left(\bigvee_{i \in S_i^+} x_i \right) \vee \left(\bigvee_{i \in S_i^-} \bar{x}_i \right), i = 1, 2, \dots, m$
CNF	<i>Formula</i>	合取范式, $CNF = \bigwedge_{i \in S} C_i, i = 1, 2, \dots, n$

Maximum Satisfiability: 找到一组 x_i 的取值, 使得满足的子句数目 $|C_i|$ 最大。

2 Algorithms

给出以下符号定义：

Symbol	Definition	Description
$E[Z_i]$	<i>Expectation</i>	期望, 对应字句 C_i 被满足的期望
$E[Z x_i]$	<i>Conditional Expectation</i>	条件期望, 在 x_i 确定取值的前提下, CNF 被满足的期望
$E[Z]$	<i>Total Expectation</i>	总期望, CNF 被满足的期望

2.1 Randomized Algorithm

- 算法描述：

将 x_i 分别以 $\frac{1}{2}$ 的概率设置为 0 或 1, 则 C_i 被满足的期望为 $E[Z_i] = 1 - 2^{-|C_i|}$,

CNF 被满足的期望为 $E[Z] = \sum_{i=1}^m E[Z_i] = \sum_{i=1}^m (1 - 2^{-|C_i|})$ 。

- 近似比分析：

设 $\min |C_i| = K$ ，则有

$$m(1 - 2^{-K}) \leq E[Z] \leq OPT \leq m$$

- 算法分析：

- ✧ 简单粗暴，易于理解；
- ✧ 结果不可控，近似比只是给出理论上期望的上界，而未必每次都能得到相应质量的解。

2.2 Derandomized Algorithm

- 算法描述：

在算法①的基础上，每个变元 x_i 都有 $\frac{1}{2}$ 的概率取 0 或 1，即有

$E[Z] = \frac{1}{2}E[Z|x_i=1] + \frac{1}{2}E[Z|x_i=0]$ 。对于每个变元 x_i ，比较 $\frac{1}{2}E[Z|x_i=1]$ 和 $\frac{1}{2}E[Z|x_i=0]$ 的大小，选择二者中期望值较大者对应的 x_i 取值。在此基础上，进行下一步迭代。

- 近似比分析：

因为每一步迭代都选择了期望值较大的，所以总的条件期望 $E[Z|x]$ 要大于随机算法的期望值 $E[Z]$ ：

$$E[Z|x] \geq E[Z] \geq m(1 - 2^{-K})$$

- 算法分析：

- ✧ 结果可控，在变元顺序确定的情况下能保证结果一致性；
- ✧ 结果与变元顺序有关，没有回溯，变元的值一旦确定便不能再更改；
- ✧ 算法复杂度较高，条件期望的计算比较耗时；
- ✧ 可能的优化方向：使用 *branch-and-bound* 的树搜索框架，通过维护一个全局的条件期望实现剪枝和加速搜索。

2.3 LP Rounding Algorithm

给出以下两个决策变量的定义：

Symbol	Definition	Description
y_i	<i>Decision Variables</i>	决策变量，变元 x_i 的 0/1 决策变量
q_i	<i>Decision Variables</i>	决策变量，子句 C_i 的 0/1 决策变量